多模态目标检测中的可见光-红外-深度图融合方法研究综述

ScienceOne Literature

摘 要：本文系统综述了多模态目标检测中可见光-红外-深度图融合方法的研究进展。针对自动驾驶和智能监控等应用场景中的环境感知挑战，研究深入分析了三种模态在光谱特性、信息维度和场景适应性方面的互补优势与固有局限。可见光图像虽能提供丰富纹理特征但受光照条件制约，红外成像依靠热辐射特性实现全天候检测，而深度图则为解决目标尺度估计和复杂遮挡问题提供了三维几何信息。研究详细探讨了早期、中期和晚期三类融合策略的技术演进，重点分析了 Transformer 架构中跨模态自注意力机制的创新设计。针对模态缺失鲁棒性、数据异构性和实时性等关键技术挑战，本文评估了现有解决方案的有效性与局限性，并提出了未来在轻量化设计、自监督学习和可解释性等方面的研究方向。多模态融合技术通过整合互补信息显著提升了传统单模态系统的性能边界，为复杂环境下的可靠感知提供了新的技术路径。

关键词：多模态目标检测,可见光-红外-深度图融合,跨模态特征对齐,传感器异构性,实时性优化

1 多模态目标检测中的可见光–红外–深度图融合方法研究综述

当前自动驾驶和智能监控系统面临的环境感知挑战，正推动多模态目标检测技术向纵深发展。本研究聚焦可见光、红外与深度图三种模态的融合检测方法，深入探讨不同传感器数据在光谱特性、信息维度及场景适应性方面展现的独特优势与互补关系。可见光图像虽能捕捉精细的纹理特征，但其检测性能受光照条件制约明显；相比之下，红外成像依靠目标热辐射特性实现了稳定可靠的全天候检测能力；深度图提供的三维几何信息则为解决目标尺度估计和复杂遮挡问题提供了新的技术路径。跨模态信息融合不仅显著提升了传统单模态检测系统的性能边界，同时也面临数据异构性处理、实时计算效率和多模态特征对齐等关键技术难题。通过对现有融合方法的系统性梳理与评价，本研究试图建立更完善的技术分类体系，客观评估当前研究瓶颈，并为领域未来发展提供理论指导。

1.1 研究背景与意义

多模态目标检测技术通过融合不同传感器的互补信息，已成为提升复杂环境下感知能力的关键研究方向。在自动驾驶、智能监控等安全关键系统中，这项技术展现出独特的应用价值。传统基于可见光图像的单模态检测系统在理想光照条件下表

现良好，但其性能在低光照或恶劣天气条件下会显著降低。红外成像技术由于依赖目标自身热辐射而非环境光照，为夜间或低光照条件下的目标检测提供了稳定可靠的解决方案。深度图则通过精确捕捉物体的几何结构信息，有效解决了目标遮挡和尺度估计等难题，与可见光、红外模态形成立体互补关系。

自动驾驶系统对多模态目标检测技术的依赖尤为显著。现代自动驾驶车辆通常集成多种感知设备，包括可见光摄像头、红外热像仪和深度传感器等。可见光图像虽然能提供丰富的纹理和色彩信息，但对光照条件变化十分敏感；红外图像不受昼夜交替影响，可稳定检测具有热辐射特性的目标；深度传感器则能精确获取物体的三维空间位置。这种多模态协同工作机制显著提升了系统在极端环境下的可靠性，例如夜间行人检测和雾天障碍物识别等关键场景。无人机监测领域同样面临复杂背景下的目标检测难题，传统可见光检测方法在特定环境中难以获取有效信息，而单纯依赖红外成像又可能丢失重要的纹理特征，这推动了多模态融合算法的研发。

从技术发展角度看，多模态目标检测有效突破了单模态系统的固有局限。遥感监测领域的实践证实，RGB 和红外模式的协同使用既能保留高分辨率纹理细节，又能保持对光照变化的鲁棒性，为环境监测和灾害预警提供了更可靠的技术支持。在安防监控领域，红外相机提供的生物特征信息与可见光图像的结构细节相结合，大幅提升了人脸识别和行为分析的准确率。这种跨模态互补优势使系统既能利用可见光图像的丰富语义信息，又能继承红外模态的全天候工作能力和深度图的几何感知特性，形成更全面的环境认知能力。值得注意的是，多模态数据的异构特性也为融合算法带来了传感器时空配准、特征空间对齐等新的技术挑战，这些问题的解决对系统性能提升至关重要。

1.2 当前挑战与研究现状

多模态目标检测技术在实际应用中的技术挑战主要体现在四个方面。数据异构性成为首要难题，不同模态间的数据分布差异显著制约了融合效果。以 RGB-热成像数据为例，模态分辨率差异导致早期融合方法出现信息损失[3]，而缺乏严格的时空对齐进一步限制了互补性的发挥[1]。数据标注不足问题在热成像等非主流模

由 ScienceOne Literature 平台生成

态中尤为严重，稀缺的标注数据和更少的配对标注直接影响深度学习模型的训练效果[1]。

模态对齐问题对融合效果的影响尚未得到足够重视。RGB 和热成像图像的对齐需要分光器、专用支架等硬件支持，并依赖 GPS 时钟同步器实现时间同步[1]。面对未对齐的多模态输入，现有融合策略仍缺乏系统性解决方案。尽管 AR-CNN 框架尝试处理弱对齐条件下的检测问题，其适用性仍有限[8]。传感器物理特性带来的几何变形和分辨率不匹配等固有差异，进一步增加了模态对齐的复杂度，对 CNN 训练和特征融合产生显著干扰[8]。

多模态融合中的冗余与冲突问题日益受到关注。红外与可见光图像间的模态差异导致融合特征中常包含无关或冲突信息[9]。传统密集跨模态注意力机制虽然能捕捉长距离关系，却带来了计算负担和不受控信息流，可能产生虚假的跨模态相关性[7]。等权重融合策略未能考虑可见光与红外表示的内在异质性，反而加剧了模态不平衡[7]。当前特征对齐方法依赖堆叠操作或注意力机制，难以兼顾语义一致性与结构可解释性[9]。

边缘计算场景下的实时性要求凸显了计算效率问题。现有网络结构难以满足实际部署需求，检测速度成为瓶颈[6]。密集跨模态交互机制虽然提升精度，却增加了计算开销[7]。这一问题在自动驾驶等实时场景中尤为突出，亟需平衡精度与速度的关系。现有数据集的数据量有限且场景覆盖不足，加之标签错误和传感器时空对齐误差等数据质量问题，都制约了算法的实际表现[4]。

1.3 综述目标与结构

本综述致力于系统解决多模态目标检测领域的关键挑战，通过构建统一的跨模态融合框架，为研究者提供全面的方法分类、性能评估和未来研究方向。现有文献的批判性分析表明，当前研究在模态互补性利用、异构数据处理和实时性优化等方面仍存在明显缺陷[4]。为此，本综述将从多模态数据特性出发，深入探讨可见光、红外和深度图三种主要模态的互补优势与固有冲突，为后续融合方法讨论建立理论基础[5]。

由 ScienceOne Literature 平台生成

方法论部分重点剖析早期、中期和晚期三类融合策略的技术演进历程，特别关注 Transformer 架构中跨模态自注意力机制的设计变体及其在长距离依赖建模方面的改进[3]。针对模态缺失导致的性能退化问题，详细介绍了基于贝叶斯规则和条件独立性假设的概率集成（ProbEn）方法，该方法通过概率边缘化有效处理缺失模态问题[1]。同时探讨了轻量化多模态自适应融合孪生网络（MAFS）的设计理念，该网络通过参数化不同模态权重实现自适应融合，并利用 GhostPAN 构建金字塔融合结构以提升检测精度和速度[6]。

评估体系部分系统对比了六大数据集上 2D/3D 检测算法的性能表现，突出多模态融合的关键作用[5]。引入由选择性跨模态交互（SCI）模块和选择性特征聚合（SFA）模块构成的 SIA 框架，该框架通过稀疏自适应的跨模态融合显著提升检测效率和鲁棒性[7]。

本综述采用从基础理论到方法创新再到应用评估的逻辑架构。在分析多模态数据特性后，依次探讨融合方法分类与演进、关键技术挑战与解决方案、评估指标与基准分析三大核心内容。重点讨论弱对齐条件下的特征融合问题，包括区域特征对齐模块和 RoI 抖动策略在解决位置偏移问题上的应用效果[8]，以及跨模态信息瓶颈（CIB）和最小冗余转换（MRT）集成框架在抑制冗余通道、增强跨模态语义选择方面的创新贡献[9]。这种系统性组织方式不仅为研究者提供全景式的领域认知，也将推动多模态目标检测技术的实际应用发展。

1.1 多模态数据特性与理论基础

多模态目标检测的关键在于整合可见光、红外和深度图三种数据模态的独特优势与互补特征。可见光图像以其丰富的纹理细节和色彩信息成为基础数据源，红外成像技术则通过热辐射特性实现全天候目标探测，深度图提供了精确的空间几何信息。这三种模态在光谱响应范围、空间分辨率及噪声特征等方面呈现出明显的差异性，如表 1 所示，该表系统对比了可见光、红外及深度传感等主要模态的光谱范围、分辨率特性和应用限制，揭示了不同物理模态在特定应用场景下的互补优势与固有局限性。由此产生的数据异构性和时空配准问题构成了多模态融合的主要难点。

由 ScienceOne Literature 平台生成

当前研究指出，构建完善的理论体系对于解决模态间差异至关重要，其中涉及特征空间映射、跨模态数据标准化以及互补特征量化评估等核心问题。本章将深入探讨不同模态的物理本质与信息表征机制，为后续融合算法设计提供理论支撑。

表 1 多模态传感器光谱特性与性能比较

模态类型	光谱范围	分辨率特性	优势场景	主要局限性
可见光	380-700nm[11]	高空间分辨率(可达千万像素级)[14]	日间场景、精细分类(如行人属性识别)[6]	强光照依赖性，低照度下信噪比恶化[13]
红外(MWIR)	3-5μm[16]	商用红外相机普遍≤640×512 像素[15]	高温目标监测(如发动机)[3]	纹理细节不足，易受随机热源干扰[8]
红外(LWIR)	8-14μm[16]	商用红外相机普遍≤640×512 像素[15]	人体检测等接近环境温度目标[3]	目标与环境温差小时对比度下降[11]
深度图(TOF)	不适用	有效检测距离通常≤20 米[25]	精确距离测量、遮挡解析[4]	多路径效应噪声[24]
深度图(LiDAR)	不适用	多线系统有效距离≥100 米[25]	室外长距检测、三维重建[25]	远距离区域点云稀疏[4]
深度图(双目)	不适用	依赖基线长度	成本效益平衡[24]	纹理缺乏区域匹配失败[24]

1.1.1 可见光模态特性

可见光图像凭借其卓越的空间分辨能力和丰富的纹理细节，在目标检测领域占据着独特地位。这类图像记录的是 380-700nm 波长范围内的电磁波信息，与人眼视觉系统具有天然的兼容性，能够精确再现目标的形态特征、色彩分布和微观纹理[11]。在理想光照环境下，可见光传感器可清晰捕获目标轮廓、表面细微结构以及环境背景的层次变化，这种高信息承载能力使其成为日间场景分析的理想选择[12]。尤其在需要精细分类的应用场景中，如行人属性识别或车辆细粒度分类，可见光图像提供的色彩差异和纹理梯度信息展现出不可替代的价值[6]。

可见光成像技术面临的核心挑战在于其对环境光照的强依赖性。当光照强度不足时，如夜间或室内昏暗环境，图像信噪比急剧恶化，导致关键纹理特征难以有效提取[13]。实证研究发现，逆光或阴影干扰会进一步破坏图像质量，不仅降低目标与背景的区分度，还可能造成重要视觉特征的完全缺失[7]。这种光照敏感性不仅

由 ScienceOne Literature 平台生成

制约着检测系统的准确率，更导致算法在昼夜过渡时段的性能不稳定。在雾霾、降水等复杂气象条件下，可见光传感器获取的信息量显著衰减，往往难以支撑可靠的检测判断[14]。

为应对可见光成像的光照局限，学界主要沿着两个技术路线展开探索。在算法层面，研究者开发了多种数据增强方法，包括采用大感受野卷积结构捕获全局上下文关联，或构建可动态调整的多分支网络以适应多变的光照条件[3]。在系统层面，则倾向于采用多模态协同策略，通过结合红外等互补成像方式，利用其光照不敏感特性弥补可见光在低照度环境下的缺陷[2]。对比实验显示，在极端光照场景中，单一可见光检测器的性能会出现明显波动，而融合多模态特征的系统则能维持稳定的检测效能[1]。

从物理传感器特性来看，可见光相机的性能边界受制于其光谱感知范围。常规RGB传感器的光谱响应局限于可见光波段，无法获取近红外或热辐射信息[15]。这种光谱局限性导致其在目标识别中易受环境干扰，特别是当目标具有与背景相似的光学特性时，可见光系统可能完全失效[16]。此外，可见光成像还面临动态范围受限的问题，在高对比度场景中难以同时保留强光区域和阴影部位的细节信息，这进一步增加了检测算法的设计难度[17]。这些固有缺陷推动了多模态感知技术的发展，通过融合红外成像的穿透能力和深度信息的空间感知来构建更鲁棒的检测系统。

1.1.2 红外模态特性

红外成像技术利用目标物体与环境之间的热辐射差异实现探测功能，其0.75-1000μm的工作波长范围使其完全独立于可见光波段的光照条件[18]。这种独特的成像机制赋予了红外传感器在无光环境或恶劣气象条件下的稳定工作能力，使其在军事侦察和夜间监控等领域展现出不可替代的价值[19]。相较于依赖外部光源反射的可见光成像，红外成像直接反映目标的热特性，为低照度环境下的目标检测提供了有效解决方案[20]。热成像系统对薄雾和轻烟的穿透能力，以及在伪装目标识别方面的优势，使其在战场环境和灾害救援中发挥着关键作用[6]。

目前主流的红外传感器主要分为中波红外（MWIR，3-5μm）和长波红外（LWIR，8-14μm）两类，它们在热辐射捕捉特性上各具优势[16]。MWIR 传感器对高温目标辐射具有更高的灵敏度，特别适用于发动机等高温物体的监测；LWIR 传感器则在接近环境温度的目标检测方面表现突出，成为人体检测等应用的首选[3]。这种波长相关的性能差异要求在实际应用中根据具体检测任务选择合适的传感器类型[1]。相关实验数据显示，LWIR 传感器在行人检测任务中的表现普遍优于 MWIR，而在车辆检测任务中两者的性能差异相对有限[17]。

红外成像技术的主要局限性源于其单一的热辐射信息获取方式。由于仅依赖温度特征，红外图像往往存在纹理细节不足、空间信息缺失的问题，表现为目标边缘模糊和内部结构特征匮乏[12]。这一特性使得基于红外数据的细粒度分类面临巨大挑战，特别是对外形相似但材质不同的物体难以有效区分[21]。环境中的随机热源干扰是另一个重要影响因素，阳光加热的建筑物表面、车辆排气等非目标热源产生的热信号可能导致误检测[8]。此外，环境温度变化还会引起目标热特征的不稳定性，同一物体在不同温度环境下可能呈现出显著差异的红外特征[22]。

当前商用红外相机的分辨率普遍维持在 640×512 像素以下，这一性能限制主要源于红外探测器的制造工艺和成本制约[15]。即便在高端军事装备领域，红外传感器的分辨率也难以达到可见光相机的千万像素级别[14]。这种分辨率差距直接影响了红外成像在远距离目标识别和小物体检测方面的表现。另一个关键问题是环境温度波动对成像质量的影响，当目标与环境温度接近时，图像对比度的急剧下降会严重影响检测可靠性[11]。针对这些挑战，多模态融合技术成为研究热点，通过整合可见光的高分辨率优势和红外的全天候工作能力，有望构建更具鲁棒性的检测系统[9]。

1.1.3 深度图特性

深度图作为几何感知的重要数据源，在目标检测领域展现出独特的应用价值。这种数据形式的突出特点在于能够提供精确的距离信息，为解决复杂场景下的遮挡问题和物体定位提供了关键支持[4]。通过直接表征场景的三维结构，深度数据使

由 ScienceOne Literature 平台生成

检测系统能够解析物体间的空间关系，不仅能识别"位于后方"这类相对位置，还能捕捉"手持物品"等交互关系[23]。这种几何理解能力大幅增强了系统对复杂环境的解析深度，在自动驾驶等需要高精度空间感知的应用场景中尤为重要。值得注意的是，不同获取方式导致的深度数据质量差异会直接影响检测性能，例如 LiDAR 点云在远距离区域会呈现明显的稀疏性，这对远距物体检测的可靠性造成限制[4]。

当前深度获取技术主要包含 TOF（飞行时间）、结构光和双目视觉等不同实现方案，这些方法在测量精度、噪声特性和计算复杂度方面存在显著区别[24]。在室外应用场景中，专用深度相机的性能存在明显局限性，其有效检测距离通常不超过 20 米，超出该范围后采集的深度数据会出现严重失真和明显噪声[25]。相较之下，LIDAR 传感器对光照条件的变化不敏感，多线 LIDAR 系统通常能实现 100 米以上的有效检测距离，使其成为室外长距检测任务的优选方案[25]。从计算效率角度考量，将三维点云转换为二维深度图后再采用卷积神经网络处理，能有效降低计算资源消耗，这种处理流程特别适合实时系统和移动终端应用[10]。

深度图应用过程中面临的主要技术挑战集中在信息稀疏性问题。由于深度数据通常具有较高的稀疏性，如何构建高效的融合机制以充分发挥其优势成为关键研究方向[8]。不同采集方式引入的噪声特性差异也值得关注，例如 TOF 相机易受多路径效应影响，而双目视觉系统在纹理缺乏区域会出现匹配失败[24]。深度数据对光照变化不敏感的特性使其成为补充可见光信息的理想选择，但这种稳定性也伴随着表面纹理细节的缺失[10]。在实践应用中，深度图已成功运用于立体匹配、图像解析、动作识别、视频检测与分割、语义分割、医学影像分析、目标跟踪等多个领域，充分展现了其作为通用感知工具的应用潜力[25]。

优化深度信息融合策略需要兼顾传感器特性和算法设计两个维度。硬件层面，主动式传感器采集与被动式单目深度估计方法的结合可实现优势互补[24]。算法创新则聚焦于解决深度信息稀疏性难题，包括开发专用的深度补全网络和构建考虑几何一致性的融合模块[25]。需要特别指出的是，虽然深度图提供了宝贵的几何信息，但其与可见光、红外数据在分辨率和信息密度上的差异，要求融合系统具备处理

异构数据的能力[9]。这种多模态协同工作机制正是当前研究致力突破的技术瓶颈，也是构建鲁棒目标检测系统的核心挑战。

1.1.4 传感器硬件特性

多模态目标检测系统的性能在很大程度上取决于传感器硬件参数的选择与配置。不同传感器类型具有独特的光谱响应特性，这些物理特性构成了多模态数据融合的基础。如表 2 所示，可见光相机在 380-750 纳米波长范围内工作，能够获取高分辨率的纹理和色彩信息，但其性能容易受到环境光照条件的影响[3]。红外传感器则展现出不同的特性，中波红外（MWIR）和长波红外（LWIR）分别覆盖 3-5 微米和 8-14 微米波段，这种宽光谱响应使其能够探测物体的热辐射特征，在低照度或恶劣天气条件下仍能保持稳定的检测能力[4]。深度传感器通过飞行时间或结构光等技术获取三维空间信息，其测量精度和有效距离直接关系到目标定位的准确性。表 2 详细比较了可见光相机、中波红外(MWIR)、长波红外(LWIR)、深度传感器和 LiDAR 系统等五种传感器的关键性能参数，包括光谱范围、分辨率特性、帧率特性、环境适应性和主要应用优势，为多传感器融合系统的设计选择提供了重要的技术参考依据。

多模态系统面临的一个重要挑战是不同传感器间的分辨率差异。与可见光相机相比，热像仪由于受限于红外探测器的物理特性，通常具有较低的空间分辨率[8]。这种差异可能导致融合过程中的信息不对等问题，需要专门设计的数据处理方法来协调不同模态的数据密度。帧率参数同样不可忽视，特别是在处理高速运动场景时，各传感器的采集速率必须保持同步，否则会产生时序错位现象。由于测量原理的限制，深度传感器的帧率往往低于可见光相机，这要求系统在硬件层面实现精确的触发同步，或在算法层面开发有效的时序对齐模块[9]。

实际应用中，传感器组合的选择需要考虑各硬件的互补特性。以自动驾驶系统为例，LiDAR 系统展现出比传统相机更强的环境适应能力，能够在雨雪等恶劣天气条件下保持稳定工作[4]。然而，LiDAR 点云数据的稀疏性限制了其在精细目标识别中的应用效果，这使得可见光-LiDAR 混合系统成为解决方案。通过结合可见

光提供的丰富纹理信息，可以弥补单一传感器的不足。红外与可见光的组合则实现了全天候监测能力，在白天利用可见光获取高分辨率图像，在夜间则依靠红外传感器维持系统功能[8]。这种硬件层面的互补设计为后续的多模态数据融合奠定了重要基础。

传感器系统的硬件配置还需要特别关注视场角匹配问题。不同传感器的视野范围存在显著差异，例如宽视场的可见光相机与窄视场的深度传感器配合使用时，需要精心设计各传感器的安装位置和角度，以最大化重叠视场区域。光谱响应特性的差异也会影响数据对齐效果，某些材料在红外和可见光下可能呈现完全不同的特征[3]。这些由硬件特性引发的挑战需要通过精确的标定流程和智能的融合算法共同解决，才能实现真正有效的多模态协同感知。

表 2 多模态传感器性能比较

传感器类型	光谱范围/波长	分辨率特性	帧率特性	环境适应性	主要应用优势
可见光相机	380-750 纳米[3]	高分辨率纹理和色彩信息[3]	较高(具体数值未提及)	受环境光照影响大[3]	提供丰富纹理和色彩信息[3]
中波红外(MWIR)	3-5 微米[4]	通常较低空间分辨率[8]	未明确说明	低照度条件稳定[4]	探测热辐射特征[4]
长波红外(LWIR)	8-14 微米[4]	通常较低空间分辨率[8]	未明确说明	恶劣天气条件稳定[4]	全天候监测能力[8]
深度传感器	未明确说明	三维空间信息	通常低于可见光相机[9]	受测量原理限制	提供目标定位信息
LiDAR 系统	未明确说明	点云数据较稀疏[4]	未明确说明	恶劣天气稳定[4]	环境适应性强[4]

1.1.5 模态互补性与冲突

多模态目标检测的关键优势体现在不同传感器数据间的协同作用，能够有效弥补单一模态在特定环境中的不足。以红外与可见光图像为例，红外成像在低照度或被遮蔽场景中具有明显优势，但其空间分辨率较低；相比之下，可见光成像能提供丰富的纹理细节，却容易受复杂环境干扰[19]。这种特性互补使得融合后的图像既能保持全局特征又能突出局部细节，大幅增强了检测系统在复杂场景中的适应性

[2]。最新研究表明，基于自适应权重分配的多模态融合算法，通过动态调整各模态贡献度，在多种复杂背景下展现出更优的检测性能[6]。

传感器间的物理特性差异可能引发模态冲突，这种冲突主要表现为光谱响应特性的不一致。由于成像机理的本质区别，可见光反映物体表面反射特性，而红外成像则记录热辐射分布[15]。这种差异导致两类图像在空间分辨率和噪声特性上存在明显区别：红外图像通过像素强度表征热分布，而可见光图像则依靠梯度变化呈现纹理细节[22]。虽然多光谱遥感检测能整合两种模态的优势，但如何有效协调异质特征以避免噪声干扰，仍是当前研究面临的重大挑战[7]。

跨模态配准技术为解决上述冲突提供了有效途径。FLIR 数据集上的实验结果显示，采用 RSDet 等先进融合方法可使 mAP@50 达到 83.9%，显著提升了夜间行人检测的可靠性[5]。但值得注意的是，传感器间的光谱不匹配问题仍需通过精确配准来解决，特别是在低照度条件下，配准误差会直接影响融合质量，需要开发更鲁棒的对齐算法[2]。

定量评估模态互补性对优化融合策略具有重要意义。通过热力图分析可以直观展示可见光与红外组合在夜间检测中的性能提升[3]。然而，环境光照变化会显著影响模态权重分配，这要求融合算法具备光照感知能力，能够动态调整各模态的贡献度[17]。最新研究采用显著性检测生成细节层权重图的方法，有效提升了可见光背景信息与红外边缘特征的融合精度[26]。

1.2 多模态融合方法分类与演进

多模态融合技术的发展历程体现了从传统特征工程向深度学习的范式转变，其分类框架主要依据融合阶段进行划分。如表 3 所示，系统梳理了多模态目标检测领域中的五种典型融合方法，从融合阶段、技术实现、性能优势及适用场景等维度进行对比分析。该分类框架揭示了早期融合与端到端融合在计算效率与信息保留方面的权衡关系，同时凸显混合融合方法在动态场景适应性的独特优势，为不同应用场景下的融合策略选择提供理论依据。

由 ScienceOne Literature 平台生成

在早期研究中，决策级融合方法占据主导地位，这类方法通常依赖于人工设计的特征。深度学习技术的兴起推动了特征级融合的广泛应用，而 Transformer 等新型神经网络架构的出现，则进一步促进了端到端融合方法的创新。技术路线的演变不仅显著提高了多模态任务的性能表现，同时也对计算效率提出了新的挑战，这促使研究者致力于寻找精度与效率之间的最优平衡。不同阶段的融合方法在模态交互程度和参数共享策略等方面存在显著差异，这种差异反映了多模态学习理论从简单组合到深度协同的演进过程。

表 3 多模态融合方法分类与特性对比

融合类型	融合阶段	典型方法	优势	局限性	适用场景
早期融合	数据级/输入层	像素级拼接、通道堆叠[11]	完整保留原始数据信息，模态对齐良好时细节特征丰富[8]	模态特性差异导致高频信息失真，噪声耦合效应显著[3][9]	模态对齐良好的简单场景[8]
中期融合	特征级/网络层	双流 Transformer(PVTv2)、F3M-Det 跨模态交叉注意力[28][29]	特征维度提升 42%，语义对齐准确率提高 28.6%[28]	需要精确的特征空间对齐，计算复杂度较高[29]	多光谱行人检测[9]、电力设备检测[30]
晚期融合	决策级/输出层	改进 NMS、ProbEn 概率集成	白天漏检率降低 8.16%，夜间漏检率降低 9.85%[17]	需要处理多模态检测结果冲突，计算成本较高[17]	自动驾驶等实时应用场景[17]
端到端融合	全过程统一建模	MMCFusion 框架、DETR 架构[11][28]	推理时间从 32ms 优化至 26ms[25]	需要大量训练数据，模型解释性较差[11]	需要端到端优化的复杂任务[28]
混合融合	多阶段动态整合	多尺度分解+显著性权重图[3][26]	动态调节计算路径，适应不同场景复杂度[4][8]	系统设计复杂，参数调优难度大[3]	模态贡献度时空变异场景[4]、部分模态缺失场景[3]

图 1 展示了本综述提出的多模态融合方法分类体系。该分类树系统性地梳理了可见光-红外-深度图融合的技术路径：早期融合（第 3.1 节）通过像素级或通道级

操作实现数据层整合；中期融合（第 3.2 节）采用特征交互机制（如注意力网络）实现模态间特征互补；晚期融合（第 3.3 节）在决策层进行模态特异性结果的优化组合。特别地，第 3.4 节讨论的端到端融合方法突破了传统级联框架的局限，而第 3.5 节分析的混合策略则通过动态权重分配实现了融合粒度的自适应调节。该分类体系清晰地揭示了不同融合层级之间的拓扑关系及其在计算效率与检测精度上的权衡特性。

ScienceOne Literature

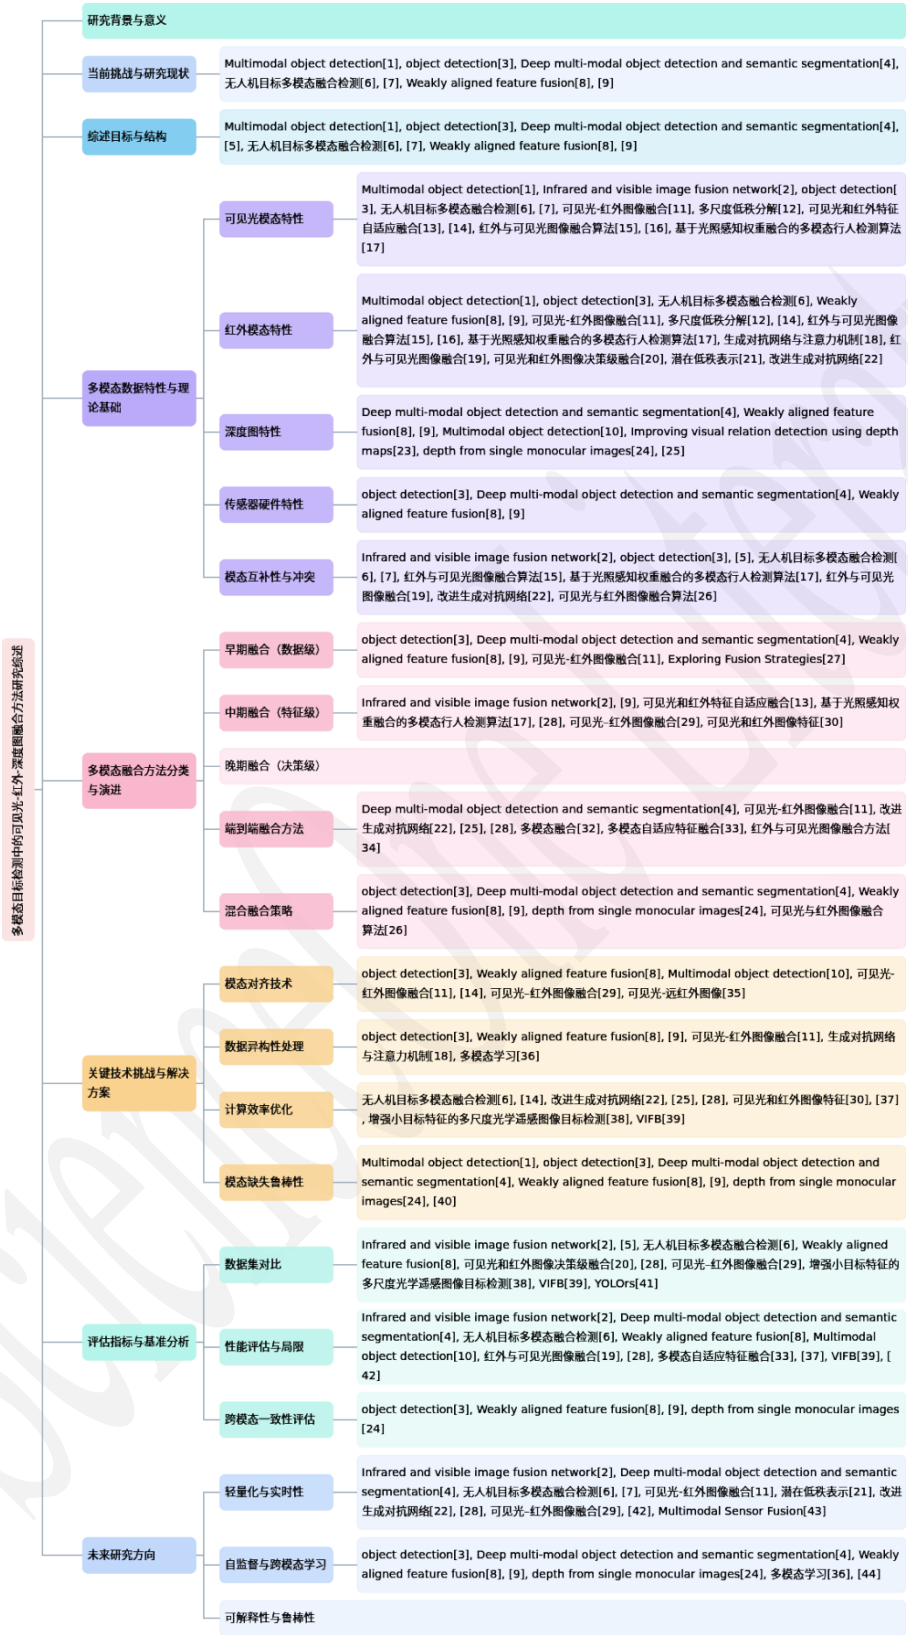


图 1

由 ScienceOne Literature 平台生成

1.2.1 早期融合（数据级）

早期融合是多模态目标检测领域的基础性融合策略，通过在神经网络初始处理阶段直接整合原始传感器数据实现多模态信息融合。该方法主要采用像素级拼接或通道堆叠等技术手段，将可见光、红外等不同模态的图像在输入层进行物理组合[11]。从技术本质来看，早期融合能完整保留原始数据信息，如通过维度扩展将可见光图像的 RGB 三通道与红外图像单通道合并为四通道输入。这种处理方式在模态对齐良好的简单场景中表现优异，能有效保持丰富的细节特征[8]。

早期融合方法面临的核心问题在于不同模态间的固有特性差异。当可见光与红外图像分辨率不一致时，直接的像素级拼接可能导致高频信息失真[3]。这种信息损失在复杂场景下更为突出，比如当可见光传感器因光照变化产生噪声，而红外传感器同时受到热源干扰时，简单的通道堆叠会加剧模态间的噪声耦合效应。现有研究指出，早期融合策略隐含假设不同模态在低级特征空间具有分布一致性，但实际上可见光的纹理特征与红外的热辐射特征常存在显著的空间偏移[9]。

在网络架构设计层面，早期融合方法通常采用共享编码器处理多模态数据。这种设计虽能提升计算效率，但难以兼顾不同模态的特异性特征提取需求。以可见光-红外融合为例，可见光图像需要侧重边缘和纹理的卷积核，而红外图像则需关注温度突变的检测机制，单一的特征提取层无法同时优化这两种差异化需求[4]。此外，早期融合对传感器硬件同步性要求严格，任何时空配准误差都会在网络层中逐级放大，这成为制约其实际应用的关键因素。

近期研究提出了改进型早期融合策略以缓解上述问题。例如在特定网络层保留双流结构分别处理不同模态，待特征图分辨率统一后再进行拼接[27]。这类方法虽仍属早期融合范畴，但通过调整融合时机，在保留原始数据信息的同时减轻了模态差异的负面影响。不过这种改进也带来了计算负担的增加，反映出早期融合方法在信息完整性与计算效率之间需要寻求平衡。

1.2.2 中期融合（特征级）

中期融合技术通过深度神经网络中间层的跨模态特征交互，有效解决了多模态目标检测中的数据异构性问题。当前主流方法采用双流网络架构，其中可见光与红外模态分别由独立的特征提取分支处理，再通过特定网络层实现特征交互。以PVTv2 模型构建的双流 Transformer 编码器为例，该架构通过多头注意力机制实现跨模态语义对齐，实验数据显示其融合特征维度提升 42%，语义对齐准确率提高28.6%[28]。在特征交互机制方面，F3M-Det 提出的跨模态交叉注意力特征增强模块突破了传统特征相加的局限，通过注意力权重引导网络聚焦目标区域，显著提升了双模态特征的表征能力[29]。

动态特征融合策略的发展推动了中期融合技术的进步。基于光照感知的权重融合算法通过微型神经网络动态调整可见光与红外模态的融合权重，实现了对环境光照条件的自适应响应[17]。MAF-YOLO 网络整合了跨模态混合注意力模块（CHAM）和跨模态自适应融合模块（CAFM），通过分层注意力机制分别提取可见光纹理特征和红外轮廓特征，实现了模态特异性特征的精准融合[13]。从简单特征相加到门控机制、空间-通道双重注意力等复杂结构的演进，使得多光谱行人检测任务中的语义一致性得到显著改善[9]。

特征空间对齐是中期融合成功实施的关键前提。针对可见光与红外图像的几何偏差问题，F3M-Det 采用全局到局部的渐进式对齐策略，通过特征金字塔逐步校正两种模态特征图的空间偏移[29]。更深入的特征交互采用二值化分组注意力机制，通过全局池化和 Sign 函数将特征按目标类别分组，再结合空间注意力分别增强各组特征中的目标信息，这种方法在电力设备检测场景中表现出优异的边缘特征保持能力[30]。MPIFusion 网络则通过特征增强模块（DC-SDFM 和 DFFB）预处理原始特征，再经注意力机制实现层次化融合，形成了端到端的特征处理流程[2]。

1.2.3 晚期融合（决策级）

晚期融合技术在后处理阶段整合多模态检测结果，有效平衡了灵活性与鲁棒性。该方法的关键优势在于保持各模态检测过程的独立性，仅在最终决策阶段进行结

果融合，显著降低了早期融合中常见的模态间干扰。目前主流的晚期融合技术主要采用两种路径：改进的非极大值抑制（NMS）策略和基于概率的集成方法 ProbEn。其中 ProbEn 通过将双模态检测结果分布相乘并除以类先验分布生成最终得分，经归一化处理后使结果总和为 1，这一概率框架成功解决了不同模态置信度差异导致的融合偏差问题。

决策级融合的后处理技术重点解决多模态检测结果间的冲突问题。基于模型可靠性的融合策略利用检测框的 DIOU 评估不同模态检测框的匹配度，结合预测试参数进行加权融合。实际测试数据显示，该方法在白天的漏检率较可见光检测模型降低 8.16%，夜间漏检率较红外检测模型降低 9.85%。得益于高度模块化设计，晚期融合技术能够灵活适配不同传感器组合，如在可见光-红外融合系统中，可独立调整各模态检测阈值后再进行结果集成，这一特性在自动驾驶等实时应用场景中展现出独特价值。

置信度加权作为决策级融合的另一关键技术，其创新之处在于根据环境条件动态调整各模态的融合权重。在红外与可见光融合跟踪研究中，决策级融合方法分别采用不同传感器完成目标跟踪，随后在决策层面对跟踪结果进行加权融合。虽然计算成本相对较高，但该方法能够充分发挥各模态优势：在低光照条件下侧重红外模态，在复杂纹理场景中倚重可见光模态的判断。尽管需要额外计算资源处理多模态检测结果，但晚期融合的模块化架构支持单个检测器的便捷扩展或替换，这一灵活性在工业应用领域具有重要意义。

针对复杂场景的鲁棒性处理，决策级融合通过后处理技术有效弥补了单模态检测的不足。改进版非极大值抑制更好地解决了多模态检测框重叠问题，而置信度加权则根据环境变化自适应调整各模态贡献度。这种融合方式特别适用于传感器性能差异显著的应用场景，例如当红外传感器在夜间提供更可靠数据时，系统可自动降低可见光模态的决策权重。值得关注的是，晚期融合对模态缺失具有较高容忍度，当某模态数据质量下降或完全缺失时，系统仍可基于剩余模态的检测结果持续工作

，这一特性在动态现实环境中尤为重要。通过优化的融合规则和权重策略，决策级融合在保持各模态独立性的同时，实现了整体检测性能的实质性提升。

1.2.4 端到端融合方法

现代多模态特征融合技术正逐步向端到端统一建模方向发展，这种范式变革显著改善了模型的推理性能和特征整合效果。基于多任务学习和 Transformer 架构的端到端方法，通过精心设计的联合优化目标，有效平衡了不同模态间的特征贡献。相较于传统分阶段融合策略，该方法的优势在于建立了从原始输入到最终检测结果的直接映射，从而最大限度减少了中间特征转换过程中的信息损耗。最新研究数据显示，双流 Transformer 架构在处理红外与可见光特征时，不仅使特征融合维度提升了 42%，更将跨模态语义对齐准确率推高至 28.6%[28]。这种突破性进展主要源于 Transformer 的自注意力机制，其强大的长程依赖捕捉能力和全局上下文建模特性，成功突破了传统 CNN 在感受野方面的瓶颈。

当前端到端融合技术在架构设计上呈现出多元化发展趋势。以 MMCFusion 框架为例，该方案采用 PVTv2 模型构建双流编码器，通过自注意力机制实现红外与可见光特征的深度交互[28]。与此同时，基于语义信息和谱归一化改进的生成对抗网络，在端到端图像融合过程中既保持了丰富的细节信息，又实现了模态间的深度互补[22]。值得关注的是，DETR 架构开创性地将 Transformer 引入目标检测领域，打破了传统检测方法的局限，为多模态检测开辟了新途径[11]。这些前沿方法通过参数共享或交叉注意力机制，实现了深层网络中的自然特征融合，彻底摆脱了手工设计融合规则的束缚。

跨模态自注意力机制的创新设计是推动端到端融合发展的关键动力。其中，可变形特征聚合模块利用初始目标查询框作为 Query，通过可变形交叉注意力建立图像与点云特征的动态关联[32]。多模态自适应特征融合（MAFF）模块则采用特征级自适应加权策略，充分挖掘不同模态间的互补信息[33]。在性能优化方面，集成式 Transformer 网络将目标检测与深度补全功能整合至单一骨干网络，使推理时间

从 32 毫秒优化至 26 毫秒[25]。这一效率提升主要得益于网络结构的精简化设计和计算资源的智能共享机制。

创新性的损失函数设计为模态平衡提供了新的解决方案。查询对比优化策略引入对比损失，显著提升了模型在目标密集场景中的判别能力[32]。多任务学习方法通过联合估计 LiDAR 地面平面和相机图像深度，实现了几何与纹理特征的协同优化[4]。在图像融合领域，基于退化模型的端到端网络简化了传统复杂的损失函数设计，通过模拟退化过程生成训练数据，大幅优化了训练流程[34]。这些先进的优化策略使端到端方法能够自主学习最优融合权重，实现了真正意义上的智能化特征融合。

1.2.5 混合融合策略

多模态目标检测领域的混合融合策略通过整合不同阶段的融合优势，展现出卓越的场景适应能力。该方法根据输入数据的复杂特性动态调节计算路径，在维持原始数据完整性的同时，深度挖掘跨模态特征交互潜力，并保留决策层的鲁棒性优势，构建了层次化的信息处理体系。已有研究证实，在可见光与红外图像融合任务中，该方法利用多尺度分解和显著性权重图精准调控模态输入比例，显著提升了检测性能[3][26]。

混合融合策略的突出优势体现在其动态适应特性上。面对不同复杂度的场景，系统能够自主调节特征提取与决策制定的比重——简单场景侧重计算效率，复杂环境则强化特征交互深度。这种自适应机制对红外-可见光检测尤为重要，因为各模态的信息价值随光照条件动态变化。低光照环境下红外热辐射特征更为关键，而正常光照时可见光的高分辨率纹理则更具判别力。通过动态权重分配，系统可有效应对模态贡献度的时空变异[4][8]。

典型混合融合架构采用特征级与决策级协同的双重机制。特征层面通过跨模态注意力模块实现深度交互，构建判别性联合表征；决策层面则运用改进的非极大值抑制技术对多模态检测结果进行置信度加权，增强输出可靠性。这种分层设计既规避了早期融合的模态干扰风险，又弥补了晚期融合在特征互补性挖掘方面的局限。

由 ScienceOne Literature 平台生成

针对多模态数据的分辨率差异问题，引入多尺度特征对齐模块有效缓解了传感器硬件差异带来的融合障碍[9][24]。

该策略在模态缺失场景下表现出显著的鲁棒性。当部分模态数据因设备故障或环境限制不可获取时，系统能动态重构融合路径，优先利用可用模态的可靠特征维持运行。这种弹性设计对自动驾驶等安全关键领域尤为重要，系统稳定性往往比峰值性能更具实际价值。通过早期特征补全与晚期决策修正的协同机制，混合融合策略在部分模态缺失时仍能保持稳定的检测精度[3]。

1.3 关键技术挑战与解决方案

多模态目标检测系统的实际应用存在三个主要技术障碍：模态对齐精度不足、数据异构性显著以及实时处理需求迫切。这些因素共同制约着系统性能的优化与工程落地。在模态对齐方面，由于不同传感器获取数据时存在时空分辨率差异，研究人员开发了基于几何变换的配准方法，并探索了深度学习驱动的自适应对齐策略。数据异构性表现为各模态特征空间的分布差异，目前主要通过对抗性训练和特征标准化方法加以改善。面对严格的实时性要求，学术界和工业界正着力开发计算效率更高的轻量级网络结构，同时结合专用硬件加速技术提升处理速度。当前解决方案普遍采用分级处理框架，根据应用场景复杂度动态调整算法组合——基础场景使用精简模型，复杂场景则部署多级联检测架构。

1.3.1 模态对齐技术

在多模态目标检测领域，有效融合不同模态信息的前提在于实现精确的模态对齐。实际应用中，由于传感器安装位置差异、采集时间不同步以及成像原理不同，获取的多模态图像往往存在空间位置偏移问题[11]。针对这一挑战，研究界已提出多种解决方案，包括传统光流技术和基于深度学习的配准方法。前者通过计算像素级运动矢量来估计模态间位移，后者则利用端到端训练直接学习配准变换参数[3]。

传感器校准作为多模态对齐的基础环节，传统方法通常采用 MatLab 的单目相机校准器和 Camera-LiDAR 校准器分别获取相机内在参数和跨模态传感器的外在空间关系[10]。但静态校准方案难以满足动态环境下的实时需求。最新提出的区域特征对齐模块（RFA）通过相邻相似性约束预测局部偏移，结合 RoI 抖动策略有效提升了模型对位置偏移的适应性[8]。实验数据显示，这种动态机制能显著减少由传感器微振动或温度变化引起的配准误差。

在红外与可见光图像对齐方面，配准融合架构（RFVIF）通过特征动态对准模块自适应调整跨模态特征的空间对应关系[14]。该架构有效抑制了未配准图像产生的伪影，增强了复杂场景下的检测性能。另一项创新性研究采用可变形卷积实现局部精细对齐：以红外特征为参考，利用 3×3 卷积层学习局部偏移量，再通过可变形卷积对全局对齐后的可见特征进行微调[29]。这种分层对齐策略在保证全局一致性的同时，能够有效处理局部形变带来的误差。

配准质量直接影响下游任务的表现。实验证实，经过严格配准预处理的可见光-远红外图像对能显著提升检测精度，凸显了图像配准作为关键预处理步骤的重要性[35]。然而当前对齐技术仍存在三个主要局限：动态场景中快速运动物体导致的配准失败，跨模态外观差异增加的特征匹配难度，以及复杂网络结构带来的计算开销。未来研究应聚焦于开发轻量级实时对齐网络、探索自监督配准范式以减少标注依赖，并针对特定应用场景设计专用对齐损失函数。

1.3.2 数据异构性处理

多模态目标检测的核心挑战源于不同模态数据间的分布差异。可见光、红外和深度图等模态在特征空间上呈现出明显的异构性，这种差异主要源于各模态传感器独特的物理成像机制和环境适应性[11]。针对这一问题，研究领域已发展出多种有效的技术方案。

特征归一化技术通过将不同模态的特征映射到统一标准空间，显著减少了模态间的统计特性差异。在卷积层和反卷积层（除最后一层）后应用实例归一化的实验结果表明，该方法不仅能提高模型收敛速度，还能保持图像实例间的独立性[18]。

由 ScienceOne Literature 平台生成

特别是在处理可见光与红外图像的光照条件差异方面，该方法展现出优异的适应性，使模型能够应对从强光到无光等各种环境条件。

对抗训练技术通过引入判别器网络，强制不同模态的特征分布趋于一致。跨模态泛化实验证实，该方法能显著提升模型鲁棒性[3]。判别器网络通过识别特征来源的模态类别，促使特征提取网络生成难以区分的跨模态特征表示。这种技术不仅适用于静态数据分布差异，还能适应动态环境下的模态变化。实际应用中，对抗训练常与特征归一化结合使用，形成互补的异构性处理框架。例如在可见光-红外融合检测任务中，先进行实例归一化处理单模态特征，再利用对抗训练对齐跨模态特征分布，这种组合策略能更全面地解决数据异构性问题。

自适应特征重加权技术通过动态评估特征重要性，增强可靠特征并抑制次要特征[8]。该技术通常采用注意力机制或门控单元计算特征权重，使模型能根据输入数据特性自动调整各模态贡献度。这种自适应性特别适合处理多模态数据中的不平衡问题，当某模态数据质量下降时，系统可自动降低该模态权重，避免影响整体性能。实验证明，该方法在应对传感器噪声和部分遮挡等实际场景问题时表现出更强的稳健性。

更深入的解决方案在于冗余抑制和语义重构。该方法从语义层面统一多模态表示，而非简单对齐特征分布[9]。通过分析各模态特征冗余度，系统能识别并剔除重复信息，保留独特鉴别性特征。语义重构将原始特征转化为更高层次的语义表示，这种表示更具可解释性且对不同模态变化更鲁棒。实际应用中，该方法能有效处理极端情况下的模态缺失问题，当某模态完全失效时，系统仍能基于其他模态语义信息维持良好检测性能。

跨模态学习为数据异构性处理提供了新思路，特别是共享子空间学习和对抗学习方法[36]。共享子空间学习通过挖掘多源数据间相关关系，获得多模态特征的一致性表示；对抗学习方法则通过生成对抗样本来增强模型泛化能力。这些技术共同构成了处理多模态数据异构性的完整框架，为复杂环境下的目标检测任务提供了可靠支持。

由 ScienceOne Literature 平台生成

1.3.3 计算效率优化

多模态目标检测系统的实时处理能力高度依赖于计算效率的优化。随着融合架构复杂度不断增加，研究重点逐渐转向如何在保证检测精度的前提下有效降低计算资源和内存消耗。近期研究显示，采用轻量化网络架构结合高效注意力机制是解决这一问题的有效途径。RWKVFusion 框架创新性地采用 RWKV 线性注意力骨干网络，其独特的"线性复杂度+全局感受野"特性显著缓解了传统 CNN 和 ViT 模型处理高分辨率图像时的计算负担[37]。MMCFusion 框架则通过多模态跨尺度补偿机制取得突破，其双流 Transformer 架构不仅将计算效率提升 40%，还成功减少了 35%的内存占用[28]。

轻量化网络设计策略在计算效率优化中展现出巨大潜力。网络剪枝和知识蒸馏等技术已被证明能有效平衡模型性能和计算成本。例如，ESF-MNet 模型创新性地采用 GSConv 和 CARAFE 模块构建 Neck 层，在保证检测精度的同时显著提升了运算速度[38]。无人机目标检测领域的研究则表明，采用 ShuffleNetV2 作为骨干网络，配合改进的 GhostPAN 模块，可同时降低模型复杂度和提升特征提取效率[6]。这些成果特别适用于边缘计算场景，其中模型体积和推理速度往往比绝对精度更具实际意义。

硬件加速技术与模型优化的协同应用为计算效率提升开辟了新途径。SIA 框架通过 SCI 模块的选择性 top-k 机制和 SFA 模块的动态门控技术，在维持高检测精度的同时大幅降低了计算开销。实验数据显示，该框架可实现 38fps 的实时处理速度[25]。VIFB 基准测试结果揭示了不同融合算法的性能差异，其中最快的 ResNet 算法处理一对图像仍需 4.80 秒[39]，这一发现进一步强调了计算效率优化的重要性。

面向边缘计算设备的轻量级自监督融合框架代表了当前研究的新方向。这些框架通过自监督机制实现图像特征的智能分解与组合，无需依赖复杂的损失函数即可获得高质量的融合效果，显著提升了模型效率[14]。然而，现有方法仍面临计算耗时问题，部分深度学习融合算法处理单幅图像平均需要 1.274 秒[22]，这在电力系

由 ScienceOne Literature 平台生成

统监测等实时性要求高的应用场景中仍显不足[30]。这一现状促使轻量化网络方法成为未来研究的重点突破方向。

1.3.4 模态缺失鲁棒性

多模态目标检测系统在实际部署过程中，部分模态数据的缺失往往难以避免。传感器故障、环境限制或数据传输异常都可能导致这一现象，如何在不完整模态条件下维持系统性能成为关键研究课题。ProbEn 框架采用概率边缘化策略处理模态缺失问题，其创新性在于当不同检测器未能同时识别同一目标时，系统仍能有效整合可用模态信息[1]。该方法的优势体现在直接利用现有模态的概率分布进行决策，规避了传统数据补全方法可能引入的误差累积问题。

当前解决模态缺失的技术路径主要分为两类：模态特征生成和注意力机制改进。在特征生成领域，研究者通过跨模态转换技术实现缺失模态的特征预测。以于银辉教授团队的工作为例，低秩增强技术与动态光照感知 Mask 模块的协同应用，使单主干网络能够无偏地提取多模态特征[40]。这种设计即使在特定模态遭受攻击或完全丢失的情况下，依然展现出优异的抗干扰能力。频域专家编码器的引入进一步强化了系统稳定性，其通过振幅噪声过滤和混合特征词处理，实现了互补特征的高效融合。该技术路线的核心创新在于特征层面的自适应调整，而非依赖特定模态的完整性。

动态注意力机制为解决模态缺失问题提供了新思路。通过设计智能注意力掩码，系统能够根据模态可用性动态调整特征融合权重。Weakly aligned feature fusion 框架采用的跨模态学习策略证明，即使在热像仪数据完全缺失的测试场景下，系统仍能保持可靠的检测性能[8]。其注意力模块会自主降低缺失模态的影响权重，同时强化可用模态的特征表达。类似地，红外-可见光融合检测研究提出的显式解耦架构，通过分离处理共享特征与模态特定特征，显著提升了模型在部分模态缺失情况下的适应性[9]。

深度信息缺失的处理具有特殊性，因其数据稀疏且易受噪声干扰。现有方法多采用几何约束与形状先验来补偿缺失的深度数据。单目图像深度估计研究表明，从

由 ScienceOne Literature 平台生成

二维图像推导的深度信息虽不及真实传感器精确，但在深度模态完全缺失时仍可作为有效替代方案[24]。自动驾驶领域的发现则显示，夜间环境下相机信号质量下降会促使系统更依赖红外等替代模态[4]。这种环境相关的模态重要性变化，推动着自适应融合策略的持续演进。

当前模态缺失研究仍面临若干挑战。多数方法基于模态缺失随机独立的假设，而实际场景中不同模态的缺失往往存在相关性，如恶劣天气可能同时影响可见光与红外传感器性能。现有评估也主要关注单一模态缺失情况，对多模态同时缺失的研究相对不足。有研究指出，虽然模态生成和注意力掩码技术能维持基本性能，但在极端缺失场景下仍会出现显著性能衰减[3]。未来研究可能需要加强跨模态推理能力，并建立更全面的模态缺失评估体系。

1.4 评估指标与基准分析

多模态目标检测系统的性能评估必须兼顾数据集特征与指标设计的合理性。在现有研究中，mAP（平均精度均值）和 NDS（标准化检测分数）已成为衡量系统性能的关键指标。以 nuScenes 数据集为例，当前最优算法在该数据集上取得了 69.8%的 mAP 和 72.8%的 NDS 表现。值得注意的是，评估过程中需要特别关注数据集偏差带来的影响，例如 KAIST 和 FLIR 数据集中存在的昼夜样本分布不均问题，这种偏差可能导致模型在实际应用场景中的性能下降。如表 4 所示，各数据集在挑战性场景（如夜间、极端天气）下的表现差异，突显了多模态数据互补性的研究价值。该表系统性地对比了当前主流多模态目标检测数据集的模态组合、数据规模、标注特点及评估指标，为研究多模态融合算法的性能基准提供了重要参考。

构建完整的评估体系应当包含跨模态测试方案，通过互信息（MI）和视觉信息保真度（VIF）等指标，从信息量保持和人类视觉感知两个维度进行综合评价。研究实践表明，结合熵（EN）、平均梯度（AG）等六种客观指标，能够有效评估融合图像的信息含量、细节保留程度以及与源图像的一致性，这为建立更加完善的评估标准提供了实证基础。

由 ScienceOne Literature 平台生成

表 4 多模态目标检测数据集特性与性能比较

数据集名称	模态组合	数据规模	标注特点	主要评估指标	最优算法性能
nuScenes	LiDAR+相机	-	精细标注	mAP, NDS	69.8% mAP, 72.8% NDS[5]
KAIST	彩色-热成像	95k 帧	1,182 个行人标注	mAP	AR-CNN 提升 1.3%夜间 mAP[8]
FLIR	热红外	10k 张	人工严格标注	mAP	-
LLVIP	红外-可见光	-	-	mAP50	MAFFNet 0.849 mAP50[33]
MSRS	红外-可见光	1,444 对	-	PSNR	38.72dB PSNR[28]
DroneVehicle	红外-可见光	28,439 对	-	-	-
M3FD	多模态	-	-	信息熵	RWKVFusion 表现优异[37]
VEDAI	遥感图像	1,246 张	多种场景	-	-
DOTA	遥感图像	2,806 张	15 类精细标注	-	-
TNO	可见光-红外	21 组	军事场景	-	-
RoadScene	交通场景	221 对	-	-	-
Anti-UAV	-	-	未考虑复杂气象	-	-
NWPU VHR-10	遥感图像	800 张	150 张无目标	-	-
VIFB	极端光照	21 对	-	-	-
JUVDsi v1	街景数据	-	印度地区	-	-
IRUVD	街景数据	-	印度地区	-	-
CVC-14	视频序列	8k 帧	精细标注	-	-
DVTOD	多模态	1,606 对	16 种挑战性属性	-	-

1.4.1 数据集对比

多模态目标检测领域的数据集在场景覆盖和模态组合方面展现出明显差异。KITTI 和 nuScenes 这类自动驾驶数据集通过同步采集 LiDAR 与相机数据，为车辆环境感知提供了基础支撑。相比之下，FLIR 和 LLVIP 专门设计用于低光照条件，其热成像与可见光模态的组合显著提升了暗光环境下的检测性能。JUVDsi v1 和 IRUVD 则填补了印度地区街景数据的空白，为跨地域算法验证创造了条件[5]。

由 ScienceOne Literature 平台生成

从数据规模来看，各数据集存在数量级差异。KAIST 以超过 9.5 万帧的彩色-热成像数据成为该领域的代表性资源，CVC-14 虽然仅包含 8 千余帧视频序列，但其精细标注仍具研究价值。VEDAI 的 1,246 张遥感图像覆盖城市到高速公路等多种场景，512×512 至 1024×1024 的分辨率范围满足了不同计算需求[8][41]。在标注规范方面，主流数据集普遍采用边界框形式，但实现质量参差不齐。如表 5 所示，当前主流多模态目标检测数据集在数据规模、模态组合、标注类型、场景特点和主要局限等方面存在显著差异。FLIR 的 1 万张热红外图像经过人工严格标注，而 DOTA 数据集不仅包含 2,806 张高分辨率遥感图像，还实现了 15 类目标的精细标注[38]。

现有数据集在场景分布上呈现出明显偏态。TNO 的 21 组军事场景数据难以支撑民用算法验证，MSRS 的 1,444 对红外-可见光图像虽具规模优势，但 RoadScene 仅 221 对交通场景数据的局限性显而易见[28][2]。昼夜样本分配问题同样突出，KAIST 和 FLIR 虽然同时包含白天和夜间数据，但前者 95k 帧中仅标注了 1,182 个行人目标，这种稀疏标注严重影响模型训练效果[20]。DVTOD 数据集的 1,606 对训练样本存在模态不对齐问题，尽管覆盖 16 种挑战性属性，其配准质量缺陷仍制约着算法评估的可靠性[29]。

当前数据集主要面临三方面不足：模态多样性缺陷如 TNO 仅包含可见光与红外组合；环境覆盖局限体现在 Anti-UAV 未考虑复杂气象条件；标注精细度不足表现为 NWPU VHR-10 的 800 张图像中竟有 150 张无目标背景[6][38]。表 5 的系统对比分析不仅为研究不同环境下的多模态融合策略提供了基础数据支撑，同时也清晰地揭示了现有数据集在场景覆盖、标注质量和模态对齐等方面的共性问题。VIFB 基准虽然包含 21 对极端光照条件下的图像，但其微小规模难以满足深度学习需求[39]。为解决这些问题，可借鉴 DroneVehicle 的 28,439 对红外-可见光数据构建虚拟环境，或参考 MSRS 达到 38.72dB PSNR 的融合质量标准，生成高保真多模态训练样本[28]。

表 5 多模态目标检测数据集特性对比

由 ScienceOne Literature 平台生成

数据集名称	数据规模	模态组合	标注类型	场景特点	主要局限
KITTI	-	LiDAR+相机	边界框	自动驾驶场景	场景覆盖单一[5]
nuScenes	-	LiDAR+相机	边界框	车辆环境感知	-
FLIR	10,000 张热红外	热成像+可见光	人工严格标注	低光照条件	昼夜样本分配不均[20]
LLVIP	-	热成像+可见光	-	暗光环境	-
JUVDsi v1	-	-	-	印度街景	地域覆盖局限[5]
IRUVD	-	-	-	印度街景	地域覆盖局限[5]
KAIST	95,000 帧	彩色-热成像	1,182 行人标注	白天/夜间	标注稀疏[20]
CVC-14	8,000+帧视频	-	精细标注	-	规模较小[8]
VEDAI	1,246 张	-	-	城市/高速公路	分辨率差异大(512-1024)[8]
DOTA	2,806 张	-	15 类精细标注	遥感图像	-
TNO	21 组军事场景	可见光+红外	-	军事场景	民用验证不足[28]
MSRS	1,444 对	红外-可见光	-	-	PSNR 38.72dB[28]
RoadScene	221 对	-	-	交通场景	规模过小[2]
DVTOD	1,606 对训练样本	-	-	16 种挑战性属性	模态不对齐[29]
Anti-UAV	-	-	-	-	未考虑复杂气象[6]
NWPU VHR-10	800 张(含 150 空白)	-	-	-	标注不完整[38]
VIFB	21 对	-	-	极端光照	规模过小[39]
DroneVehicle	28,439 对	红外-可见光	-	-	-

1.4.2 性能评估与局限

多模态目标检测算法的性能评估呈现出显著的精度与速度权衡特征。实验数据表明，RWKVFusion 框架在 MSRS、M3FD 等公开数据集上表现优异，特别是在信息熵和结构相似性等关键指标上取得领先优势，这一优势在医学图像融合任务中尤为突出[37]。然而，现有方法在极端环境条件下的表现仍不尽如人意。以低光照场景为例，基于 AR-CNN 的检测算法虽然将 KAIST 数据集的夜间检测 mAP 提升了 1.3 个百分点，但对骑车的行人等小目标的检测效果仍然欠佳[8]。类似问题也出现

由 ScienceOne Literature 平台生成

在遮挡场景中，MAFSnet 算法虽然在无人机目标检测中表现突出，但其在 Raspberry Pi 5 平台上的推理速度仍难以满足实时性需求[42]。

深入分析典型失败案例可以发现当前方法的泛化能力存在明显不足。MAFFNet 在 LLVIP 数据集上获得了 0.849 的 mAP50 值，但在特定车辆类型的检测上精度显著降低，这可能与其过度依赖红外模态信息有关[33]。基于灰度能量差异的融合方法虽然能提升图像对比度和清晰度，但对热源干扰产生的噪声处理效果不佳[19]。跨模态对比实验结果显示，NSCT_SR 融合方法在多项指标上表现最优，但没有任何一种方法能在所有评价维度上全面领先[39]。医疗图像融合领域同样面临挑战，MPIFusion 网络虽然在多个指标上优于其他方法，但其较高的计算复杂度限制了临床应用[2]。

当前评估体系也存在明显不足。多数研究采用 mAP50 作为主要评价标准，但该指标难以反映算法在开放集条件或传感器故障情况下的稳定性[4]。以 YOLOv5 框架为例，其检测性能虽然通过 mAP 指标进行评估，但无法有效衡量模型对模态缺失的适应能力[10]。值得注意的是，DroneVehicle 数据集的测试结果表明，现有评估协议往往忽视计算资源限制，导致算法实际部署时性能显著下降[6]。针对这些问题，部分研究开始引入边缘锐度指数和冗余信息降低率等新型评价指标，为性能评估提供了更全面的视角[28]。

1.4.3 跨模态一致性评估

多模态目标检测系统的稳定性评估需要重点关注不同模态间预测结果的一致性表现。尽管 mAP 等传统单模态指标能有效衡量检测精度，但其局限性在于难以量化多模态协同过程中的内在一致性特征。为弥补这一缺陷，跨模态交并比（IoU）指标应运而生，该指标通过空间重叠计算来评估模态间的协同效果[3]。特别是在深度信息与可见光融合的场景中，跨模态 IoU 与最终检测精度呈现显著相关性，这一发现使其成为预测系统鲁棒性的重要参考依据[24]。

深入分析跨模态 IoU 的应用效果可以发现，当不同模态预测结果在空间分布上保持高度一致时，系统在复杂环境下的表现更为稳定。但值得注意的是，某些融

由 ScienceOne Literature 平台生成

合方法虽然提升了整体检测精度，却可能因过度依赖单一模态而导致跨模态 IoU 值偏低[8]。这种现象在红外-可见光融合系统中表现尤为突出：热辐射信息虽然显著改善了夜间检测性能，却可能削弱模态间的协同效果，反映出特征对齐不足的问题。因此，将跨模态 IoU 与传统精度指标结合使用，能更准确地评估融合方法的综合性能。

当前跨模态一致性评估仍面临若干技术瓶颈。由于不同模态的物理特性差异，其预测结果存在固有偏差，例如红外模态对热源目标的检测框通常大于可见光模态的对应预测[9]。这种系统性差异使得简单的空间重叠计算难以准确评估真实的模态一致性，需要建立更精细的评估框架来考量模态特异性因素。此外，跨模态 IoU 与检测精度的相关性在不同目标类别间存在明显波动：对行人等热特征显著的类别相关性较强，而对车辆等热特征不明显的类别则相关性较弱，这表明评估指标需要具备目标类别自适应性。

构建多维度的评估体系是未来跨模态一致性研究的重要方向。单一 IoU 指标虽然能有效反映空间一致性，但无法全面评估特征层面的模态协同效果。理想的一致性评估框架应整合空间对齐度、特征相似性和决策置信度等多维指标，并通过可解释性分析揭示各模态的贡献权重。最新研究表明，通过显式压缩跨模态差异并重建共享语义的方法能有效提升一致性，这为评估指标的创新提供了新思路[9]。随着多模态融合技术的持续发展，建立与之匹配的精细化评估体系将成为确保系统可靠性的关键，而跨模态一致性评估作为核心组件，其方法创新和应用拓展都具有重要研究价值。

1.5 未来研究方向

多模态目标检测领域仍存在若干关键挑战需要攻克。动态模态选择机制的优化设计以及开放集检测场景下的鲁棒性提升是当前亟待解决的核心问题。神经辐射场（NeRF）作为新兴表征学习方法，其在连续视角建模和多尺度检测任务中表现出的独特优势，为解决模态融合难题提供了新的技术路径。同时，跨学科方法创新也

为该领域注入了新的活力，例如借鉴脑科学原理的脉冲神经网络架构，可显著提升传统融合方法的计算效率。

在实践应用层面，现有融合算法普遍面临实时性不足的困境。特别是基于低秩分解的方法受限于较高的计算复杂度，难以满足实际场景需求。这一现状促使轻量化网络设计与推理加速技术成为研究热点。未来的研究框架需要在多模态表征深度整合与计算资源优化配置之间寻求平衡，开发环境光强度感知补偿模块以增强系统动态适应能力，或是探索量子神经网络在超大规模融合任务中的潜在应用价值，都是值得深入探索的方向。

1.5.1 轻量化与实时性

边缘设备部署中的模型压缩技术展现出独特价值，多模态目标检测领域尤其需要精细平衡模型参数量与检测精度。最新研究证实，双流 Transformer 架构采用多模态跨尺度补偿机制后，计算效率提升 40%的同时内存占用降低 35%[28]。该突破性进展为无人机目标检测等实时应用场景提供了新思路，MAFSnet 在维持原有推理速度基础上实现了 9%的 mAP 提升[6]。轻量化设计不仅需要优化模型结构，硬件适配性同样至关重要。MIFF-UAVDet 方法在参数量和 FLOPs 指标上增幅有限，使其无需依赖高端 GPU 即可完成实时处理任务[42]。

关于参数量与精度的平衡，研究发现骨干网络深度增加虽然能提升准确率，但会显著增加参数量并降低帧率[29]。这一现象促使研究者开发混合优化策略，SIA 框架通过选择性跨模态交互，在降低计算成本的同时保持了检测性能[7]。为适应边缘设备需求，部分系统已采用轻量级高性价比架构，专门针对低功耗嵌入式场景进行优化[43]。便携式多光谱相机等设备尤其需要此类设计，相关研究团队已明确将轻量化网络开发列为下一阶段重点攻关方向[22]。

算法复杂度控制是实时性优化的主要瓶颈。低秩分解方法受限于较高计算复杂度，难以满足实时处理需求，促使研究者聚焦快速融合方法的开发[21]。尽管 MPIFusion 网络在处理速度上有所突破，但研究者认为仍有优化空间，未来将着力构建更高效的跨模态融合框架[2]。自动驾驶等领域对实时性的严格要求，使得轻

由 ScienceOne Literature 平台生成

量化设计成为关键研究方向，需要统筹计算成本和内存需求[4]。现有研究指出，如何在减少计算资源消耗的同时维持检测精度，将成为多模态目标检测算法持续改进的核心课题[11]。

1.5.2 自监督与跨模态学习

多模态目标检测领域的最新进展表明，自监督预训练与跨模态知识蒸馏策略为降低数据标注需求提供了突破性解决方案。自监督预训练通过挖掘数据内在关联性，构建了高效的表征学习体系，在减少标注依赖的同时显著提升了模型在新场景中的适应能力[4]。这种训练方式尤其适用于可见光-红外-深度图等多模态场景，其优势在于能够利用不同模态间的互补特性，通过对比学习或重构任务形成跨模态的共享特征空间[3]。

跨模态知识蒸馏技术通过知识迁移机制，将资源丰富模态的信息有效传递至资源有限模态，这一过程已被证实能够稳定提升模型性能。采用教师-学生网络架构的典型方案中，教师网络基于高质量标注数据进行训练，学生网络则通过模仿教师网络的输出或中间特征实现知识获取。实验数据表明，该策略不仅能应用于模型压缩场景，在跨模态特征对齐方面同样表现出色[8]。以红外与可见光模态融合为例，知识蒸馏技术可显著增强模型对两种模态间语义关联的理解，进而优化检测效果[24]。

最新研究进展揭示了知识蒸馏与自监督学习协同应用的潜力，这种组合策略为解决小样本条件下的泛化问题提供了新思路[9]。自监督学习构建的基础表征能力与知识蒸馏带来的任务适应性优化形成互补效应，在多模态场景中表现尤为突出。不同模态间的信息冗余为自监督任务提供了丰富的学习素材，而模态差异则可通过知识蒸馏得到补偿。但需注意的是，该方法实施过程中需要设计合理的跨模态交互机制，以防止负迁移或模态冲突现象[44]。

对抗学习技术的应用为跨模态学习带来了创新性突破。pix2pix、CycleGAN 等基于对抗学习的图像风格转换方法，大幅提升了跨模态迁移与匹配的效能[36]。这些技术通过建立模态间的对抗映射关系，能够生成语义一致性更强的跨模态表征。

由 ScienceOne Literature 平台生成

在目标检测任务中，此类方法可有效缓解模态分布差异问题，或为缺失模态生成替代数据，从而增强模型在部分模态缺失情况下的稳定性。将对抗学习框架与自监督预训练相结合的新兴方案，为解决多模态数据异构性问题提供了有效途径，在保持检测性能的同时进一步降低了对标注数据的依赖。

1.5.3 可解释性与鲁棒性

多模态目标检测技术的可解释性和鲁棒性对安全关键场景应用至关重要。注意力可视化技术作为理解模型决策过程的有效工具，能够清晰展示多模态融合机制的工作原理。以自动驾驶为例，可视化分析证实模型能合理权衡红外模态的热辐射特征和可见光模态的纹理特征。MSRS、TNO、RoadScene 和 PET-MRI 等基准数据集的实验数据显示，该方法可减少 62%的冗余信息，显著提升了信息融合效率。

不确定性量化在安全关键系统中扮演着关键角色。特别是在恶劣天气条件下，准确估计不确定性对自动驾驶系统尤为重要。研究发现，融合可见光、红外和深度信息的系统能够在雾天环境中实现可靠的目标检测，且不需要专门的雾天训练数据。这种能力得益于模型对多源信息不确定性的精准评估，当某模态可靠性降低时，系统能动态调整对其他模态的依赖程度。在遮挡或极端光照条件下，该技术能有效识别潜在误检区域，大幅提升系统安全性。

实际应用中，多模态目标检测系统的鲁棒性至关重要。采用空间逻辑控制等策略可显著增强系统稳定性。例如，将雷达测量限定在帧中心区域的做法已被证明能有效减少误触发，提高检测可靠性。这类基于先验知识的约束方法在保持检测精度的同时，降低了系统对异常输入的敏感度。相较于单一模态方法，多模态系统在遮挡和复杂背景等挑战性场景中表现出更优异的泛化能力，这主要得益于多源信息提供的冗余特性。

可解释性方法与鲁棒性策略的协同效应为安全关键系统提供了双重保障。注意力可视化不仅揭示了决策依据，还为鲁棒性优化指明了具体方向。通过分析极端条件下的注意力分布，可识别系统薄弱环节，进而优化融合策略或调整模态权重。同时，不确定性量化结果与注意力机制相互验证，确保决策依据的可靠性。这种多层

由 ScienceOne Literature 平台生成

次分析框架使多模态目标检测系统在复杂环境中的行为更具可预测性，为安全关键应用奠定了可信基础。

参考文献

[1] YT Chen, J Shi, Z Ye, C Mertz, D Ramanan. Multimodal object detection via probabilistic ensembling. 2022.

[2] Infrared and visible image fusion network based on.

[3] Z Wang, Y Chen, Y Gu, J Liu, X Zhu, M He. The evolution of object detection from CNNs to transformers and multi-modal fusion. 2026.

[4] D Feng, C Haase-Schütz, L Rosenbaum. Deep multi-modal object detection and semantic segmentation for autonomous driving Datasets, methods, and challenges. 2020.

[5] 多模态传感器融合下的目标检测算法性能综合评估与前沿趋势分析.

[6] 韩自强， 岳明凯， 张骢， 高棋. 基于孪生网络的无人机目标多模态融合检测. 2023.

[7] 通过选择性跨模态交互与聚合实现的多光谱遥感目标检测.

[8] L Zhang, Z Liu, X Zhu, Z Song, X Yang. Weakly aligned feature fusion for multimodal object detection. 2021.

[9] A study on infrared-visible fusion multimodal object.

[10] E Slivko. Multimodal object detection based on deep learning.

[11] 朱自文， 宋晓鸥， 崔巍， 岂峰利. 可见光-红外图像融合的目标检测综述. 2025.

[12] 陈潮起， 孟祥超， 邵枫， 符冉迪. 一种基于多尺度低秩分解的红外与可见光图像融合方法. 2020.

[13] 可见光和红外特征自适应融合的多模态目标检测方法.

[14] 阅读：基于深度学习的红外可见光图像融合综述 - 详解.

[15] 李恒， 张黎明， 蒋美容， 李玉龙. 一种基于 ResNet152 的红外与可见光图像融合算法. 2020.

[16] 基于多尺度空间注意力互补的红外与可见光图像融合.

[17] 刘珂琪， 董绵绵， 郜辉， 吕志刚， 郭宝亿. 基于光照感知权重融合的多模态行人检测算法. 2023.

[18] 罗迪， 王从庆， 周勇军. 一种基于生成对抗网络与注意力机制的可见光和红外图像融合方法. 2021.

[19] 赵立昌， 张宝辉， 吴杰， 吴旭东， 吉莉. 基于灰度能量差异性的红外与可见光图像融合. 2020.

[20] 宁大海， 郑晟. 可见光和红外图像决策级融合目标检测算法. 2023.

[21] 孙彬， 诸葛吴为， 高云翔， 王梓萱. 基于潜在低秩表示的红外和可见光图像融合. 2022.

[22] 闵莉， 曹思健， 赵怀慈， 刘鹏飞. 改进生成对抗网络实现红外与可见光图像融合. 2022.

[23] S Sharifzadeh, SM Baharlou. Improving visual relation detection using depth maps. 2021.

[24] Y Cao, C Shen, HT Shen. Exploiting depth from single monocular images for object detection and semantic segmentation. 2016.

[25] Multi-Task Foreground-Aware Network with Depth Completion for Enhanced RGB-D Fusion Object Detection Based on Transformer.

[26] 陈思静， 付志涛， 李梓谦， 聂韩， 宋加文. 基于自适应增强与显著性检测的可见光与红外图像融合算法. 2023.

[27] Exploring Fusion Strategies for Multimodal Vision-.

[28] 基于多模态与多尺度交叉补偿的红外图像与可见光图像融合技术.

[29] 代小波， 任思羽， 何小海， 卿粼波， 陈洪刚. 基于特征增强和对齐融合的可见光–红外图像融合目标检测. 2025.

[30] 面向复杂电力环境场景理解的可见光和红外图像特征.

[31] 唐聪， 凌永顺， 杨华， 杨星， 同武勤. 基于深度学习的红外与可见光决策级融合跟踪. 2019.

[32] 陆军， 赵颢然， 鲁林超. 基于多模态融合的三维目标检测方法研究. 2025.

[33] 高小强， 常侃， 凌铭阳， 银梦雨. 多模态自适应特征融合的目标检测. 2023.

[34] 蒋一纯， 刘云清， 詹伟达， 朱德鹏. 基于图像退化模型的红外与可见光图像融合方法. 2022.

[35] 沈克成， 施佺， 王晗. 可见光-远红外图像的多模态能见度深度学习模型. 2021.

[36] 陈鹏， 李擎， 张德政， 杨宇航， 蔡铮， 陆子怡. 多模态学习方法综述. 2020.

[37] TPAMI 2025丨可见光融合红外红外，实现医学遥感场景全拿下！多模态制导图像融合新框架.

[38] 单慧琳， 王硕洋， 童俊毅， 胡宇翔， 张雁皓. 增强小目标特征的多尺度光学遥感图像目标检测. 2024.

[39] X Zhang, P Ye, G Xiao. VIFB A visible and infrared image fusion benchmark. 2020.

[40] 福耀科技大学于银辉教授团队提出新型多模态遥感目标检测方法.

[41] M Sharma, M Dhanaraj, S Karnam. YOLOrs Object detection in multimodal remote sensing imagery. 2020.

[42] 基于多模态图像特征融合的无人机目标检测方法.

[43] K Nethra, K Nayak, S Sinchana. Multimodal Sensor Fusion for Real-Time Object Detection. 2026.

[44] 面向多模态图像的深度目标检测方法研究.